Informe Técnico

Nombre: Diego Castro Saavedra
Evaluación: Evaluación 1 — Análisis de *Paddy Dataset*
Fecha: 22 de octubre de 2026
Fuente de datos: Subramaniyan, M. (2023). *Paddy Dataset* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C55W3J.

Índice de Contenidos

1. Metodología de Trabajo
2. Limpieza de Datos (Sección 1.1)
3. Análisis Exploratorio de Datos (Sección 1.2)
4. Modelación Predictiva (Sección 1.3)
5. Ficha de Asesoría Agrícola (Sección 1.4)
6. Limitaciones del Dataset
7. Conclusiones y Recomendaciones
8. Reproducibilidad del Proyecto

---

1. Metodología de Trabajo

El análisis se desarrolló utilizando las siguiente herramientas de línea de comandos de Unix:

- **Obtención (`curl`, `unzip`):** Descarga automatizada del archivo comprimido desde el repositorio UCI y extracción en `data/`.
- **Limpieza (`file`, `head`, `cat -A`, `wc`, `tr`, `sed`, `sort`, `uniq`, `awk`, `csvstat`):** Inspección del tipo de archivo y caracteres ocultos, eliminación de retornos de carro DOS (`\r`), estandarización de encabezados a `snake_case`, validación de nulos y coherencia lógica, eliminación de duplicados exactos y creación de variables por hectárea.
- **Exploración (`csvcut`, `csvstat`, `awk`, `python3`, `rush plot`):** Cálculo de estadísticos descriptivos, conteo de valores únicos (cardinalidad), verificación de invarianza de clima por bloque e insumos por hectárea, resúmenes agrupados, correlaciones de Pearson y gráficos de caja (*boxplots*).
- **Modelación (`shuf`, `awk`, `vw`, `python3`):** Partición aleatoria reproducible 70/30 con semilla fija (42), conversión al formato de espacios de nombres de *Vowpal Wabbit*, ajuste de modelos lineales con pérdida cuadrática (`--loss_function squared`) y evaluación de MAE y R^2 en el conjunto de prueba.

---

2. Limpieza de Datos (Sección 1.1)

Inspección de formato y mapeo de columnas

Al ejecutar `file data/paddydataset.csv`, la herramienta identificó el archivo como `CSV text`. Al inspeccionar las primeras líneas con `head -n 5 data/paddydataset.csv | cat -A`, se detectó que las líneas terminaban con el carácter de retorno de carro DOS/Windows `^M$` (`CRLF`, `\r\n`) y que los nombres de las columnas presentaban espacios finales (`Hectares `), espacios internos, mayúsculas, barras (`/`) y paréntesis.

Se eliminaron los retornos de carro mediante `tr -d '\r'` y se normalizó el encabezado con `tr` y `sed`, obteniendo nombres simples y consistentes en `snake_case`:

N°	Nombre Original	Nombre Nuevo	N°	Nombre Original	Nombre Nuevo
1	`Hectares`	`hectares`	25	`Max temp_D1_D30`	`max_temp_d1_d30`
2	`Agriblock`	`agriblock`	26	`Min temp_D31_D60`	`min_temp_d31_d60`
3	`Variety`	`variety`	27	`Max temp_D31_D60`	`max_temp_d31_d60`
4	`Soil Types`	`soil_types`	28	`Min temp_D61_D90`	`min_temp_d61_d90`
5	`Seedrate(in Kg)`	`seedrate_in_kg`	29	`Max temp_D61_D90`	`max_temp_d61_d90`
6	`LP_Mainfield(in Tonnes)`	`lp_mainfield_in_tonnes`	30	`Min temp_D91_D120`	`min_temp_d91_d120`

N°	Nombre Original	Nombre Nuevo	N°	Nombre Original	Nombre Nuevo
7	Nursery	nursery	31	Max temp_D91_D120	max_temp_d91_d120
8	Nursery area (Cents)	nursery_area_cents	32	Inst Wind Speed_D1_D30(in Knots)	inst_wind_speed_d1_d30_in_knots
9	LP_nurseryarea(in Tonnes)	lp_nurseryarea_in_tonnes	33	Inst Wind Speed_D31_D60(in Knots)	inst_wind_speed_d31_d60_in_knots
10	DAP_20days	dap_20days	34	Inst Wind Speed_D61_D90(in Knots)	inst_wind_speed_d61_d90_in_knots
11	Weed28D_thiobencarb	weed28d_thiobencarb	35	Inst Wind Speed_D91_D120(in Knots)	inst_wind_speed_d91_d120_in_knots
12	Urea_40Days	urea_40days	36	Wind Direction_D1_D30	wind_direction_d1_d30
13	Potassh_50Days	potassh_50days	37	Wind Direction_D31_D60	wind_direction_d31_d60
14	Micronutrients_70Days	micronutrients_70days	38	Wind Direction_D61_D90	wind_direction_d61_d90
15	Pest_60Day(in ml)	pest_60day_in_ml	39	Wind Direction_D91_D120	wind_direction_d91_d120
16	30DRain(in mm)	30drain_in_mm	40	Relative Humidity_D1_D30	relative_humidity_d1_d30
17	30DAI(in mm)	30dai_in_mm	41	Relative Humidity_D31_D60	relative_humidity_d31_d60
18	30_50DRain(in mm)	30_50drain_in_mm	42	Relative Humidity_D61_D90	relative_humidity_d61_d90
19	30_50DAI(in mm)	30_50dai_in_mm	43	Relative Humidity_D91_D120	relative_humidity_d91_d120
20	51_70DRain(in mm)	51_70drain_in_mm	44	Trash(in bundles)	trash_in_bundles
21	51_70AI(in mm)	51_70ai_in_mm	45	Paddy yield(in Kg)	paddy_yield_in_kg
22	71_105DRain(in mm)	71_105drain_in_mm	46	*(Variable calculada)*	rendimiento_ha
23	71_105DAI(in mm)	71_105dai_in_mm	47	*(Variable calculada)*	trash_ha
24	Min temp_D1_D30	min_temp_d1_d30			

Verificación de filas respecto a la ficha del repositorio

La ficha del repositorio UCI declara 2.790 instancias. El comando `wc -l data/paddydataset.csv` arrojó 2.790 líneas, que corresponden a 1 fila de cabecera y 2.789 filas de datos. La diferencia de 1 fila se debe a que el repositorio contabilizó la línea de encabezados dentro del total de instancias.

Valores faltantes y coherencia de los datos

- **Valores faltantes:** Mediante `csvstat data/paddy_renamed.csv --nulls` se comprobó que las 45 columnas tienen `False` (0 valores faltantes).
- **Coherencia de los datos:** Con `awk` se verificó que en ninguno de los 4 tramos (`D1_D30`, `D31_D60`, `D61_D90`, `D91_D120`) la temperatura mínima supera a la máxima (0 incoherencias), y que los valores de superficie (`hectares > 0`), residuos (`trash_in_bundles >= 0`) y rendimiento (`paddy_yield_in_kg > 0`) se encuentran en rangos plausibles y positivos (0 errores).

Filas duplicadas y conteo antes y después de cada paso

Con `tail -n +2 data/paddy_renamed.csv | sort | uniq -d | wc -l` se detectaron 361 perfiles distintos repetidos. Al eliminar las repeticiones con `sort | uniq`, los registros pasaron de 2.789 a 2.338 filas únicas, eliminándose 451 copias duplicadas exactas. Se justificó su eliminación porque, al no existir identificador de predio ni fecha, las filas idénticas distorsionan las frecuencias reales y generan fuga de información entre entrenamiento y prueba.

Paso del pipeline	Archivo	Líneas totales (`wc -l`)	Filas de datos (sin cabecera)
1. Archivo original	`data/paddydataset.csv`	2.790	2.789
2. Conversión a Unix (`tr -d '\r'`) y renombre	`data/paddy_renamed.csv`	2.790	2.789
3. Eliminación de duplicados (-451 copias)	`data/paddy_dedup.csv`	2.339	2.338
4. Creación de `rendimiento_ha` y `trash_ha`	`data/paddy_clean.csv`	2.339	**2.338**

3. Análisis Exploratorio de Datos (Sección 1.2)

Estadísticos descriptivos (`csvstat`)

Variable	Mínimo	Mediana	Media	Máximo	Desv. Estándar	Valores Únicos
`hectares`	1	4	3,736	6	1,450	6
`paddy_yield_in_kg`	5.410	24.644	22.610,118	38.814	9.265,185	477
`rendimiento_ha`	5.410	5.964	5.985,004	6.469	289,353	175

Cardinalidad (`csvstat --unique`)

- **Variables categóricas:** `agriblock` (6), `variety` (3), `soil_types` (2) y `nursery` (2). En estas variables categóricas es esperable tener pocos valores distintos.
- **Superficie e insumos:** `hectares` y las 10 columnas de insumos agrícolas tienen exactamente 6 valores distintos cada una, mientras que `trash_ha` tiene solo 3 valores distintos (80, 90 y 100 fardos/ha).
- **Clima:** Las lluvias y riegos tienen solo 3 valores distintos, la velocidad del viento 3 a 4 valores, y las temperaturas, direcciones de viento y humedades 5 a 6 valores. En variables ambientales continuas no es esperable una cardinalidad tan baja en 2.338 parcelas, lo que revela que fueron asignadas de forma agregada.

Comprobación del clima por `Agriblock` e insumos por hectárea

- **Clima por bloque:** Al extraer con `awk` cada bloque junto con sus 24 variables de clima (`sort | uniq | cut -d, -f1 | sort | uniq -c`), cada uno de los 6 bloques (`Chinnasalem`, `Cuddalore`, `Kallakurichi`, `Kurinjipadi`, `Panruti`, `Sankarapuram`) presenta exactamente 1 combinación climática (`1`). Esto implica que el clima es constante dentro de cada bloque y solo actúa como etiqueta geográfica regional.
- **Insumos por hectárea:** Al dividir los 10 insumos por `hectares` en las 2.338 filas (`awk ... | sort | uniq -c`), las 2.338 filas arrojan 1 única combinación constante (`25` kg/ha de semilla, `12.5` t/ha abono campo, `20` cents/ha vivero, `1` t/ha abono vivero, `40` kg/ha DAP, `2` herbicida, `27.13` kg/ha urea, `10.38` kg/ha potasio, `15` kg/ha micronutrientes y `600` ml/ha pesticida). A su vez, `trash_ha` solo toma los valores 80 (831 filas), 90 (611 filas) y 100 (896 filas). Esto implica que los insumos fueron calculados multiplicando una receta fija por el número de hectáreas, sin variabilidad empírica entre agricultores.

Distribución de superficies y rendimiento medio

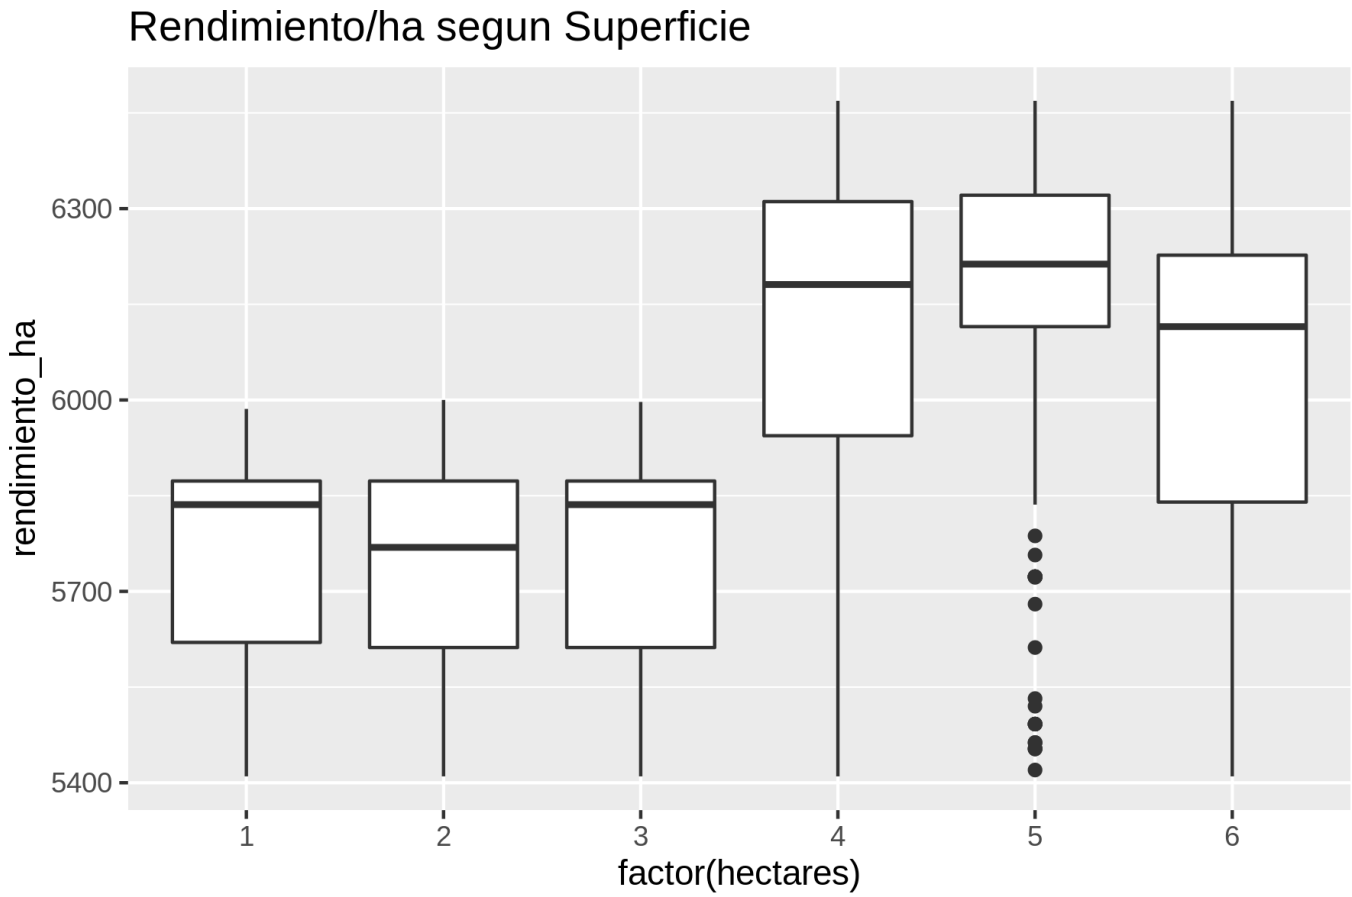
`hectares`	N° de Registros	Rendimiento Total Medio (kg)	`rendimiento_ha` Medio (kg/ha)
1	203	5.745,69	5.745,69
2	357	11.479,49	5.739,75
3	366	17.211,61	5.737,20
4	533	24.435,94	6.108,98
5	686	31.015,47	6.203,09
6	193	36.256,38	6.042,73

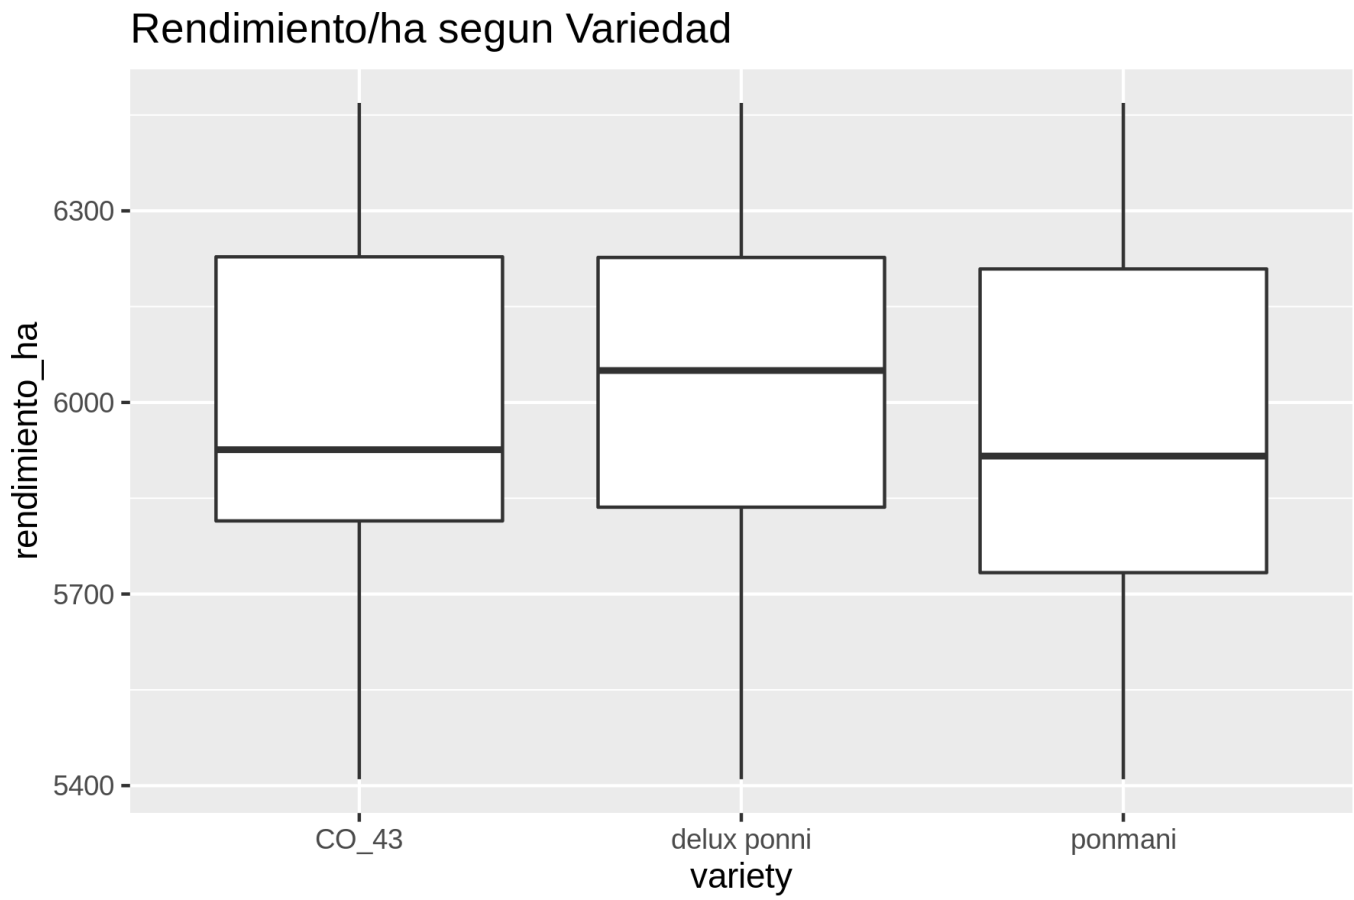
Rendimiento por hectárea según `Variety`, `Soil Types`, `Nursery` y `Agriblock`

Variable	Categoría	Media `rendimiento_ha` (kg/ha)	Desv. Estándar (kg/ha)
Variety	`delux ponni` / `CO_43` / `ponmani`	6.005,74 / 5.990,02 / 5.962,30	285,78 / 293,96 / 288,19
Soil Types	`clay` / `alluvial`	5.987,96 / 5.981,50	289,93 / 288,77
Nursery	`wet` / `dry`	5.986,92 / 5.983,35	291,93 / 287,21
Agriblock	`Sankarapuram` / `Chinnasalem` / `Kurinjipadi`	6.003,52 / 5.989,77 / 5.986,52	291,00 / 292,84 / 289,89
Agriblock	`Kallakurichi` / `Panruti` / `Cuddalore`	5.978,08 / 5.972,58 / 5.972,11	282,88 / 291,53 / 287,57

Correlaciones y Visualizaciones

- **Correlación `hectares` vs `paddy_yield_in_kg` = `0.9943`:** Correlación lineal positiva casi perfecta porque el rendimiento total depende directamente del área cosechada.
- **Correlación `hectares` vs `rendimiento_ha` = `0.5949`:** Correlación positiva moderada-alta, producto del incremento de rendimiento por hectárea que se observa en las parcelas de 4 a 6 ha en comparación con las de 1 a 3 ha.





Tres hallazgos exploratorios clave

1. **Salto escalonado de rendimiento en 4 y 5 ha:** El rendimiento por hectárea es prácticamente constante en predios de 1, 2 y 3 ha (~5.737 a 5.746 kg/ha), pero da un salto abrupto en 4 ha (6.108,98 kg/ha) y alcanza su máximo en 5 ha (6.203,09 kg/ha), disminuyendo levemente en 6 ha (6.042,73 kg/ha).
2. **Baja diferenciación por suelo, vivero, variedad y bloque:** Las diferencias en el promedio de `rendimiento_ha` según suelo (6,46 kg/ha entre `clay` y `alluvial`), vivero (3,56 kg/ha entre `wet` y `dry`), bloque agrícola (31,41 kg/ha entre extremos) y variedad (43,44 kg/ha entre `delux ponni` y `ponmani`) son mínimas frente a la desviación estándar general (289,35 kg/ha).
3. **Rigidez en insumos y clima (limitación del dataset):** La totalidad de los insumos divididos por hectárea son constantes y el clima no varía dentro de cada bloque agrícola, lo que indica una construcción tabular o normativa de los datos.

---

4. Modelación Predictiva (Sección 1.3)

Resultados en el conjunto de prueba (partición 70/30, semilla 42)

Modelo	Variables Incluidas	MAE (kg/ha)	R^2 (Prueba)
Modelo Base	Promedio de `rendimiento_ha` del entrenamiento	252,89	-0,0577
Modelo A (manejo)	`variety`, `soil_types`, `nursery`, `trash_ha`	245,35	-0,0140
Modelo B (clima)	24 variables numéricas de lluvia, temp., viento y humedad	239,02	-0,0045
Modelo C (superficie)	Solo `hectares`	179,73	0,3430
Modelo D (todas)	Todas las variables de A, B y C	177,13	0,3413

- **Modelo de Contraste (Rendimiento total `paddy_yield_in_kg` usando solo `hectares`):** MAE = 836,44 kg, R^2 = 0,9870.

Interpretación de los Modelos

- **(i) ¿Qué modelo predice mejor y qué grupos de variables aportan información?**
  Los modelos **C (superficie)** y **D (todas)** logran el mejor desempeño, con **R^2 = 0,3430** y **R^2 = 0,3413**, reduciendo el MAE a **179,73** y **177,13 kg/ha** respectivamente. Los modelos **A (manejo)** y **B (clima)** obtienen R^2 cercanos a cero (-0,0140 y -0,0045). Esto demuestra que la **superficie (`hectares`)** es el único grupo que aporta señal predictiva sustantiva.

- **(ii) ¿Por qué el R^2 del rendimiento total es muy alto y por qué se prefiere el rendimiento por hectárea?**
  El R^2 del rendimiento total es **0,9870** porque la producción total es el producto entre las hectáreas y el rendimiento por hectárea; como este último tiene muy baja dispersión relativa (coeficiente de variación de 4,83%), el tamaño del predio determina casi mecánicamente el volumen total cosechado. Se prefiere modelar `rendimiento_ha` porque normaliza el efecto de tamaño y mide la eficiencia productiva por unidad de tierra.
- **(iii) ¿Qué patrón sugiere la relación entre superficie y rendimiento por hectárea y qué limitaciones tiene un modelo lineal para describirla?**
  La relación sigue un patrón **escalonado no lineal** (meseta de ~5.740 kg/ha en 1–3 ha, salto a ~6.109–6.203 kg/ha en 4–5 ha y baja a 6.043 kg/ha en 6 ha). Un modelo lineal solo puede ajustar una recta de pendiente constante, por lo que no logra representar simultáneamente el tramo plano inicial, el salto intermedio y la caída final.
- **(iv) A partir de la exploración, ¿es creíble concluir que el clima o el manejo no influyen en el rendimiento, o es una limitación de los datos? Justificar.**
  No es creíble concluir que el clima o el manejo no influyan agronómicamente; es una **limitación estructural de los datos**. En el dataset los insumos por hectárea son constantes para todos los registros y las variables climáticas toman un único vector por bloque agrícola. Al no existir variación empírica independiente en esas variables, ningún modelo puede identificar su efecto.

---

5. Ficha de Asesoría Agrícola (Sección 1.4)

El pipeline genera e imprime automáticamente el archivo `report/ficha.txt`:

```
Programa de Extension Agricola - Ficha de Asesoria
Asesor: dst
Registros unicos analizados: 2338
Rendimiento medio: 5985.00 kg/ha
Superficie de mayor rendimiento medio: 5 ha
R2 del modelo de superficie (prueba): 0.3430
```

---

6. Limitaciones del Dataset

- **(i) Insumos normativos sin variación real:** Los 10 insumos agrícolas son múltiplos exactos de la superficie (`hectares`), reflejando una tabla teórica de recomendación y no la dosis real aplicada en cada parcela.
- **(ii) Clima agregado por bloque:** Las 24 variables meteorológicas tienen un único valor por cada `agriblock`, impidiendo distinguir variaciones microclimáticas o entre temporadas.
- **(iii) Alta proporción de duplicados y baja dispersión:** Se encontraron 451 copias duplicadas exactas en el archivo bruto y una desviación estándar muy reducida (~289 kg/ha sobre una media de 5.985 kg/ha), lo que sugiere datos altamente estandarizados o sintéticos.

---

7. Conclusiones y Recomendaciones

- **Conclusión:** El análisis demuestra que, una vez depurados los 451 registros duplicados (quedando 2.338 registros únicos), las variables de manejo y clima no poseen capacidad predictiva sobre la eficiencia del cultivo debido a su falta de varianza en el dataset. El único predictor que explica parte de la variación del rendimiento por hectárea es la superficie (hectares, R^2 = 0,3430), impulsado por el salto de rendimiento registrado en los predios de 4 y 5 hectáreas.
- **Recomendación al Programa de Extensión Agrícola:** Se recomienda verificar primero en terreno si el salto de rendimiento observado en los predios de 4 a 5 ha es un fenómeno agronómico real o un artefacto de cómo se construyó el dataset antes de utilizarlo para recomendar prácticas a los agricultores. Asimismo, es indispensable rediseñar la recolección de datos en futuras campañas para medir las dosis de insumos realmente aplicadas por parcela, asignar identificadores únicos de predio e incorporar mediciones meteorológicas locales.

---

8. Reproducibilidad del Proyecto

El proyecto, ya cuenta con los permisos para su ejecuccion, basta con utilizar el comando `bash scripts/pipeline.sh` y se ejecutara la siguiente secuencia: (1.1) descarga, limpieza de formato, validación de nulos/coherencia, deduplicación y cálculo de data/paddy_clean.csv;

(1.2) estadísticos, cardinalidad, pruebas de clima/insumos, correlaciones y gráficos PNG en report/; (1.3) partición 70/30, entrenamiento en vw y tabla de métricas; y (1.4) creación e impresión de report/ficha.txt.